

Introducao Redes Neurais Artificiais - RNA (ANN)

1. Definição

São modelos computacionais inspirados nos mecanismos de aprendizagem do cérebro humano

Modelos computacionais que tentam emular a forma com que o cérebro resolve problemas

O Cérebro é:

O processamento de informações no cérebro humano é altamente complexo, não-linear e paralelo.

Constituído de aproximadamente 100 bilhões de neurônios

Cada neurônio é interligado em média com outros 6 mil neurônios (60 trilhões de sinapses)

Equivale a quantidade de estrelas na Via Láctea

Sistema mais complexo conhecido atualmente pelo homem

2. Características das RNA's

Adaptação por experiências: Parâmetros internos da rede são ajustados a partir da apresentação sucessiva de exemplos (amostras e medidas)

Capacidade de aprendizado: Aplicação de método de treinamento possibilita a rede extrair o relacionamento entre variáveis que compõe a aplicação

Habilidade de generalização: Após o processo de treinamento, a rede é capaz de generalizar o conhecimento adquirido, possibilitando a estimação de soluções que eram até então desconhecidas.

Organização de dados: Baseado em características marcantes de um conjunto de dados à respeito do processo, a rede é capaz de realizar sua organização interna para agrupamento de amostras que são similares/comuns

Tolerância a falhas: Devido ao elevado nível de interconexões entre neurônios artificiais, a rede torna-se um sistema tolerante a falhas quando parte de sua estrutura for sensivelmente corrompida

Armazenamento distribuído: O conhecimento dentro da rede é realizado de forma distribuída entre as sinapses dos neurônios artificiais, permitindo-se então robustez frente a eventuais neurônios que se tornam inoperantes.

Facilidade de prototipagem: A implementação de maioria das arquiteturas neurais pode ser facilmente prototipadas em hardware ou software

Após o processo de treinamento, os seus resultados são normalmente obtidos por algumas operações matemáticas elementares

4. Características e representação dos neurônios

• Representação do neurônio biológico

Fluxo de Informações

Dendritos

Corpo Celular

Axônio

• Etapas de variação (potencial de ação)

35

25

15

5

-5

-15

-25

-35

-45

-55

-65

-70

0

1

2

3

4

5

6

ms

Potencial de ação (máximo)

Disparo

Excitação

Potencial de ativação (limiar)

Potencial de repouso

Característica	Dimensão
Massa do cérebro	1,5 kg
Energia consumida	20%
Comprimento do neurônio	100µm
Potencial de repouso	-70 mV
Potencial de ativação	-55 mV
Potencial de ação (máximo)	35 mV

x_1

w_1

x_2

w_2

x_n

w_n

\sum

$- \theta$

u

$g(\cdot)$

y

$y = g(u)$

$u = \sum_{i=1}^n w_i \cdot x_i - \theta$

- Sinais de entrada $\rightarrow \{x_1, x_2, \dots, x_n\}$
- Pesos sinápticos $\rightarrow \{w_1, w_2, \dots, w_n\}$
- Combinador linear $\rightarrow \{\Sigma\}$
- Limiar de ativação $\rightarrow \{\theta\}$
- Potencial de ativação $\rightarrow \{u\}$
- Função de ativação $\rightarrow \{g\}$
- Sinal de saída $\rightarrow \{y\}$

Modelo Matemático do neurônio artificial

3. Aplicações das RNA's

Exemplos: Solução de diversos tipos de problemas em diferentes áreas do conhecimento.

Aproximador de Funções: Utilizadas para mapear relações complexas entre variáveis quando a modelagem tradicional é difícil.

Exemplos: Controles em robótica, aeronaves, elevadores, eletrodomésticos, satélites, entre outros.

Controle de Processos: Servem para identificar ações de controle que garantam qualidade, eficiência e segurança.

Exemplos: Reconhecimento de imagem, voz e escrita.

Classificação de Padrões: Usadas para associar entradas a classes pré-definidas.

Exemplos: Diagnóstico médico (identificação de classes), compressão de dados, data mining.

Agrupamento de Dados (Clusterização): Servem para identificar similaridades e agrupar dados.

Exemplos: Previsão de demanda de energia, mercados financeiros, clima, séries temporais.


Sistemas de Previsão: Com o objetivo de estimar valores futuros com base em dados passados.

Exemplos: Otimização restrita, otimização combinatória, sequenciamento de produção.

Otimização de Sistemas: Visam minimizar ou maximizar funções objetivo, considerando restrições.

Exemplos: Processamento de imagens, transmissão de sinais, identificação de caracteres manuscritos.

Memórias Associativas: Permitem recuperar padrões completos mesmo com entradas incompletas ou distorcidas.



- I. Apresentação de um conjunto de valores que representam as variáveis de entrada do neurônio.
- II. Multiplicação de cada entrada do neurônio pelo seu respectivo peso sináptico.
- III. Obtenção do potencial de ativação produzido pela soma ponderada dos sinais de entrada, subtraindo-se o limiar de ativação.
- IV. Aplicação de uma função de ativação apropriada, tendo-se como objetivo limitar a saída do neurônio.
- V. Compilação da saída a partir da aplicação da função de ativação neural em relação ao seu potencial de ativação.

Passos para obtenção da resposta (saída)